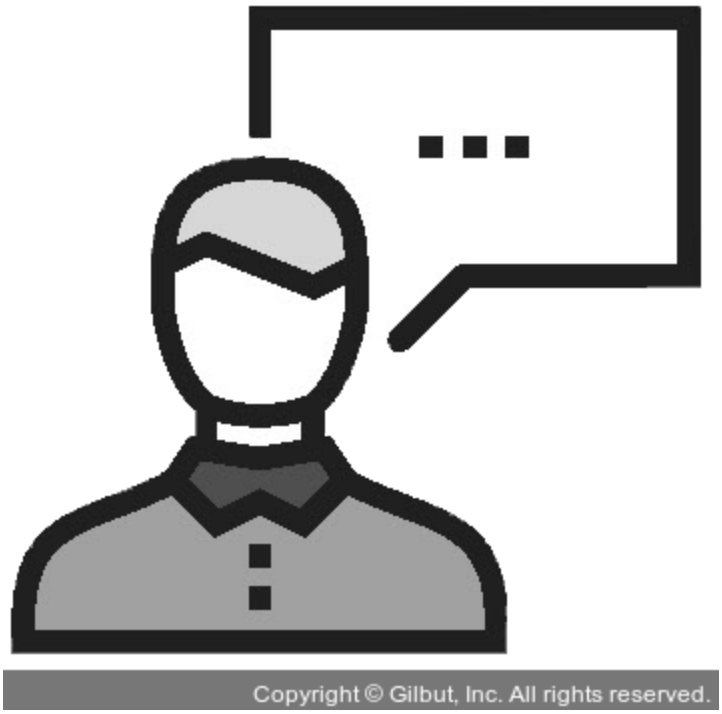
UNIT 02
서울의 기온 데이터 분석하기



⦿ 실습 데이터 Unit02/unit02-01.ipynb, seoul.csv

1 CSV 파일에서 데이터 읽어오기

파이썬의 CSV 모듈에는 데이터를 읽어오기 위한 `reader()` 함수와 데이터를 저장하기 위한 `writer()` 함수가 있습니다.

- `csv.reader()` : CSV 파일에서 데이터를 읽어오는 함수
- `csv.writer()` : CSV 파일에 데이터를 저장하는 함수

지금부터 본격적으로 `reader()` 함수를 사용하여 CSV 파일에 저장된 데이터를 읽어오는 방법에 대해 알아보겠습니다. 참고로 이 책에서 `writer()` 함수는 다루지 않습니다.

■ CSV 파일 다운로드

❶ Unit 1에서처럼 기상자료개방포털(https://data.kma.go.kr)의 기후통계분석 → 기후분석 → 기온분석 메뉴로 들어가 '기간'은 1904년 1월 1일부터 2019년 1월 17일까지로 설정하고, '지역'은 서울로 설정한 다음 검색 버튼을 누릅니다. 그래프가 나오면 CSV 다운로드 버튼을 누릅니다.

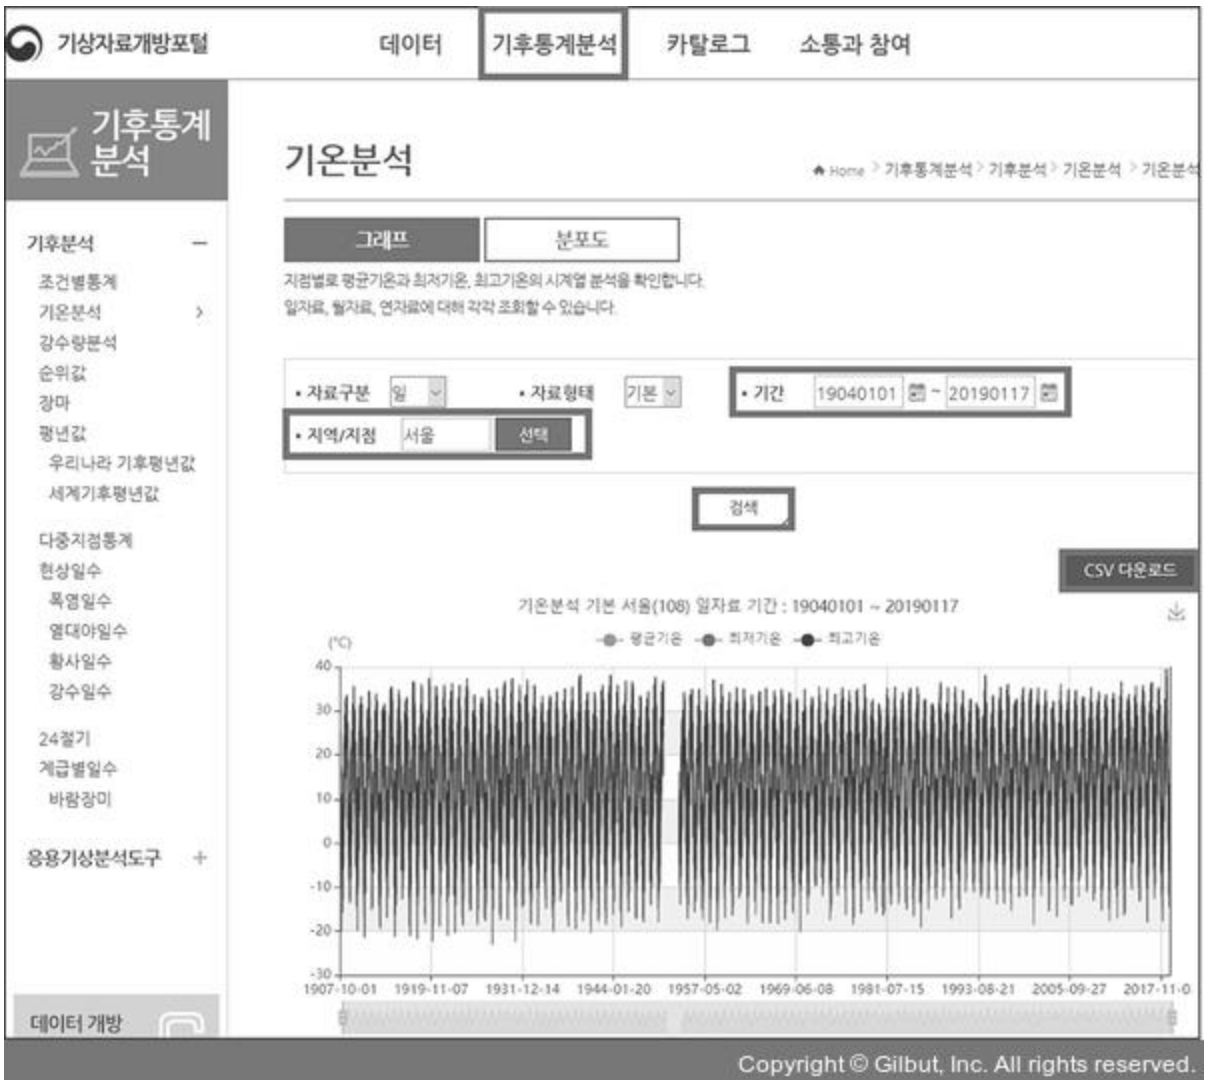


그림 2-1 1907년부터 현재까지의 기온 데이터 다운로드

TIP

이 책을 편집하는 시점인 2019년 1월을 기준으로 설정합니다. 때에 따라 '현재' 시점은 달라질 수 있으니, 처음에는 연습을 위해 책처럼 기간을 설정할 것을 권장합니다.

■ 주피터 노트북 실행하기

지금부터는 아나콘다가 설치되어 있고 기본 브라우저를 크롬으로 설정했다고 가정하고 실습을 진행하겠습니다. 만약 아직 아나콘다를 설치하지 않았다면 Unit 1을 참고하여 설치를 먼저 진행하세요.

❶ 작업 표시줄의 윈도 키를 눌러서 Anaconda3 폴더의 Jupyter Notebook 아이콘을 클릭합니다.

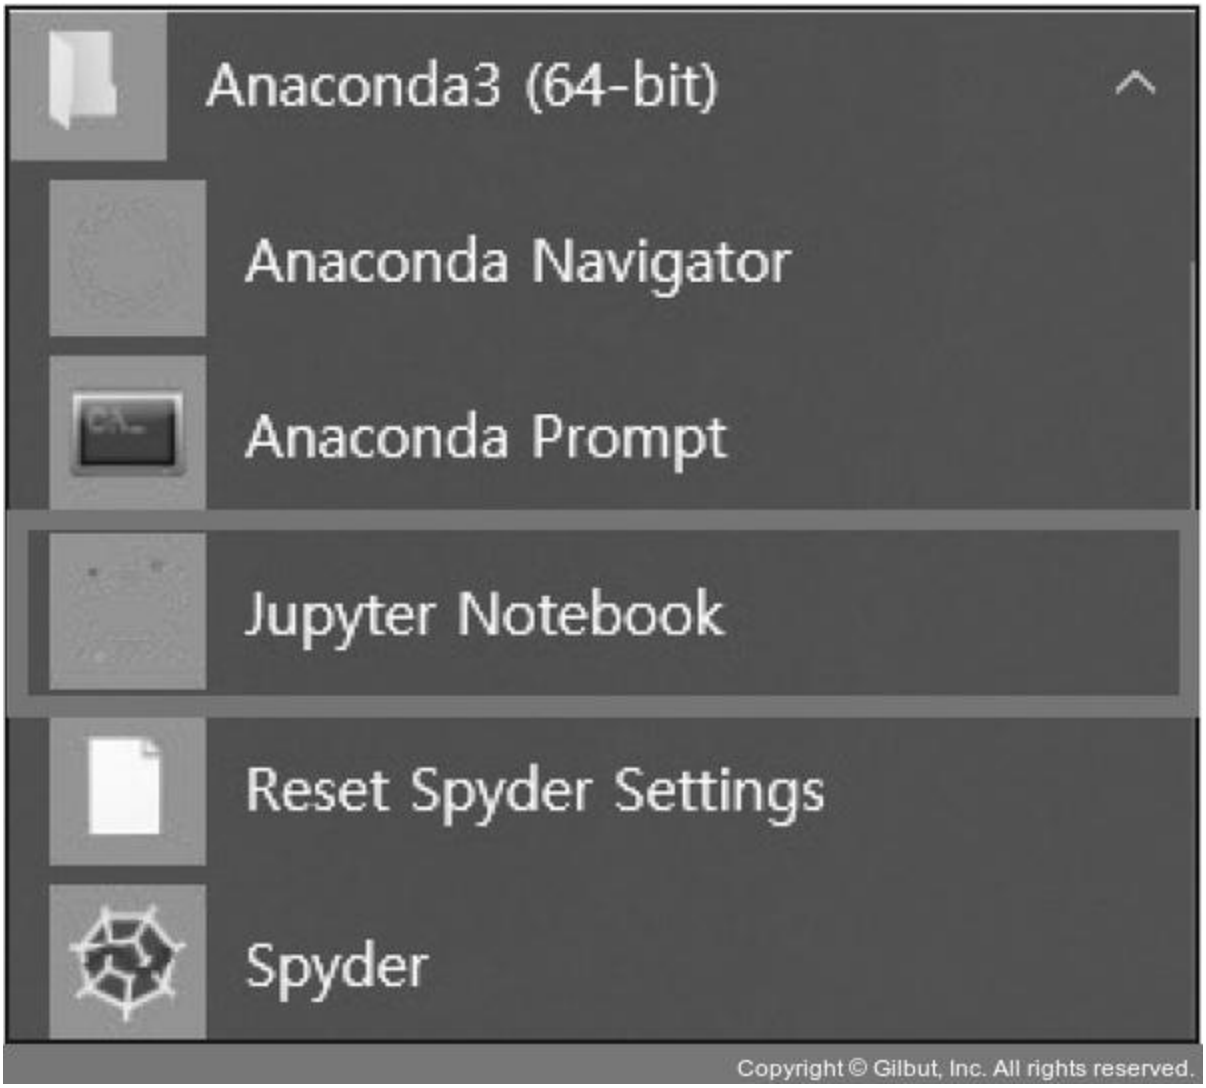


그림 2-4 Anaconda3 폴더의 Jupyter Notebook 클릭



잠깐만요

‘주피터 노트북’이란?

‘주피터 노트북’은 오픈 소스 기반의 웹 애플리케이션으로, 파이썬을 비롯한 40여 개의 프로그래밍 언어로 코드를 작성하고 실행하는 개발 환경을 제공합니다. 파이썬으로 작성한 여러 개의 코드와 실행 결과를 하나의 문서처럼 관리할 수 있으며, 데이터 분석을 위해 여러 종류의 라이브러리를 불러온 후 일부 코드의 실행 결과를 확인할 수 있다는 특징이 있습니다.

기존의 파이썬 IDLE을 사용하는 것과 비교했을 때, 일부 코드의 실행 결과를 확인할 수 있고 문서화하여 다른 사람과 공유하기가 편리하다는 장점이 있습니다. 아나콘다를 설치하면 주피터 노트북을 바로 사용할 수 있습니다.

2 데이터 출력하기

`for` 반복문을 사용하면 CSV 파일에 저장된 데이터를 한 줄씩 읽어올 수 있습니다. 기존 코드에서는 `print(data)`로 파일에 저장된 데이터 전체를 출력했는데, 이번에 작성할 코드에서는 CSV 파일에 저장된 데이터를 한 줄씩 출력합니다.

앞서 작성한 unit02-01의 코드를 다음과 같이 수정합니다(수정된 부분을 굵게 표시했습니다).

```
import csv
f = open('seoul.csv', encoding='cp949')
data = csv.reader(f)
for row in data :
    print(row)──▶ 4칸 들여쓰기에 주의하세요!
f.close()
```

실행 결과

```
['날짜', '지점', '평균기온(℃)', '최저기온(℃)', '최고기온(℃)']
['1907-10-01', '108', '13.5', '7.9', '20.7']
['1907-10-02', '108', '16.2', '7.9', '22']
['1907-10-03', '108', '16.2', '13.1', '21.3']
['1907-10-04', '108', '16.5', '11.2', '22']
(생략)
```

TIP

1907년부터 현재까지의 데이터를 출력하므로 실행 결과가 나오기까지 시간이 걸릴 수 있습니다.

3 헤더 저장하기

이번에는 수많은 데이터를 다룰 때 표지판과 같은 역할을 하는 헤더를 저장해볼까요? '헤더(header)'는 데이터 파일에서 여러 가지 값들이 어떤 의미를 갖는지 표시한 행을 말합니다. 많은 경우, 헤더는 데이터의 첫 번째 줄의 위치하여 두 번째 줄부터 나타나는 데이터의 속성을 설명합니다. 헤더를 통해 각 열의 데이터가 어떤 의미를 갖는지 알 수 있기 때문에 매우 중요한 데이터입니다. 헤더를 별도로 저장하려면 `next()` 함수를 사용할 수 있습니다.

주피터 노트북에서 만든 unit02_01 파일에서 + 버튼을 눌러 새로운 셀을 생성한 후 다음과 같이 입력해 봅시다.

TIP

주피터 노트북의 코드는 셀 단위로 구분하여 작성할 수 있습니다. 각 셀의 왼쪽 옆에는 In[숫자] 형식의 태그가 생성됩니다. 주피터 노트북에서 같은 셀의 내용을 수정한 후 다시 실행해 볼 수 있고, 같은 파일 안에 다른 셀을 만들어 일부 코드 수정 후 실행해 볼 수도 있습니다.

```
import csv
f = open('seoul.csv')
data = csv.reader(f)
header = next(data)    # ❶
print(header)          # ❷
f.close()
```

실행 결과

```
['날짜', '지점', '평균기온(℃)', '최저기온(℃)', '최고기온(℃)']
```

4 기온 공공데이터에 질문하기

지금까지 CSV 파일을 어떻게 다루는지 알아보았습니다. 아직 익숙하지 않더라도 이 책의 대부분 프로젝트에서 CSV 파일을 다루기 때문에 곧 익숙해질 것입니다. 그럼 지금부터 기온 공공데이터를 살펴보면서 질문을 해 볼까요?

책에서는 지면 관계상 데이터의 일부만 보여주지만, 여러분은 내려받은 seoul.csv 파일을 엑셀 프로그램에서 열어서 서울 지역의 기온 데이터를 한번 천천히 살펴보길 바랍니다.

	A	B	C	D	E
1	날짜	지점	평균기온(°C)	최저기온(°C)	최고기온(°C)
2	1907-10-01	108	13.5	7.9	20.7
3	1907-10-02	108	16.2	7.9	22
4	1907-10-03	108	16.2	13.1	21.3
5	1907-10-04	108	16.5	11.2	22
6	1907-10-05	108	17.6	10.9	25.4
7	1907-10-06	108	13	11.2	21.3
8	1907-10-07	108	11.3	6.3	16.1
9	1907-10-08	108	8.9	3.9	14.9
10	1907-10-09	108	11.6	3.8	21.1
11	1907-10-10	108	14.2	6.4	24.1
12	1907-10-11	108	15.4	10.1	20.4
13	1907-10-12	108	13.9	11.1	17.4

Copyright © Gilbut, Inc. All rights reserved.

그림 2-10 서울 지역의 기온 데이터

이 책에서는 다음 두 가지 가설을 전제합니다.

- 데이터 분석은 내가 관심 있는 데이터에 대한 호기심에서 출발한다.
- 나와 직접적으로 관련이 있는 매력적인 데이터를 살펴보면 궁금증이 생긴다.